

TÊN TRƯỜNG

KHOA ...

Nhận Dạng Từ Khóa Ít Mẫu Tập Mở ở Quy Mô Từ Vựng Lớn

Nghiên Cứu Học Độ Đo về Bộ Trích Xuất Đặc Trưng,
Bộ Mã Hóa và Phương Pháp Từ Chối Tập Mở

Đồ Án Tốt Nghiệp Kỹ Sư

Sinh viên: *Tên Sinh Viên*

Giảng viên hướng dẫn: *TS. Trần Hoàng Tùng*

Cơ sở hạ tầng: *TS. Trần Giang Sơn (Máy chủ ICTLab)*

Ngày 19 tháng 6 năm 2026

Lời Cảm Ơn

Trước hết, em xin bày tỏ lòng biết ơn sâu sắc tới giảng viên hướng dẫn, TS. Trần Hoàng Tùng, vì những phản hồi sâu sắc và sự hướng dẫn tận tình trong suốt 3 tháng thực tập. Em cũng xin chân thành cảm ơn TS. Trần Giang Sơn đã tạo điều kiện cho em toàn quyền sử dụng máy chủ ICTLab, giúp phần tính toán của đề án thành công tốt đẹp.

Xin cảm ơn gia đình đã luôn động viên và ủng hộ về mặt tinh thần, giúp em duy trì động lực và hoàn thành đề án này. Cuối cùng, xin cảm ơn những ai đã dành thời gian đọc toàn bộ đề án; chúc các bạn có một trải nghiệm đọc thú vị.

Mục lục

Lời Cảm Ơn	1
1 Giới Thiệu	4
1.1 Tóm Tắt	4
1.2 Bối Cảnh và Động Lực	5
1.3 Mục Tiêu Đề Tài	6
1.4 Kết Quả Kỳ Vọng	6
1.5 Giải Thích Bài Toán Theo Ngôn Ngữ Thông Thường	6
2 Kiến Thức Nền Tảng và Các Công Trình Liên Quan	9
2.1 Từ Âm Thanh Đến Dữ Liệu Số	9
2.2 Biểu Diễn Thời Gian-Tần Số: Mel-Spectrogram	9
2.3 Nhận Dạng Từ Khóa: Tập Đóng vs. Tập Mở	10
2.4 Học Ít Mẫu và Học Độ Đo	11
2.5 Phân Loại Biên Góc và Từ Chối Tập Mở	12
3 Phương Pháp Đề Xuất	14
3.1 Phát Biểu Bài Toán	14
3.2 Bộ Dữ Liệu và Giao Thức Huấn Luyện	15
3.3 Kiến Trúc Hệ Thống	16
3.3.1 Bộ Trích Xuất Đặc Trưng	16
3.3.2 Bộ Mã Hóa	18
3.3.3 Các Hàm Mục Tiêu Học Độ Đo	19
3.4 Các Đầu Từ Chối Tập Mở	20
3.5 Phương Pháp Đánh Giá	20
3.6 Thiết Kế Thực Nghiệm: Những Gì Chúng Tôi Đo	21
3.7 Triển Khai: Phát Trực Tuyến và Bản Demo	21
4 Kết Quả và Phân Tích	23
4.1 Diễn Biến Huấn Luyện	23
4.2 Q1: Trục Thiết Kế Nào Quan Trọng	23
4.3 Q2: Quy Mô — Bảo Hòa và Sụp Đổ SCAF	24

4.4	Q3: Chứng Cắt Đổi Kiến Thức Giáo Viên Lấy Dữ Liệu	25
4.5	Q4: Các Hệ Thống Triển Khai Tốt Nhất	26
4.6	Suy Luận Trên Audio Dài	27
5	Kết Luận	31
5.1	Hiện Trạng	31
5.2	Điểm Mạnh và Điểm Yếu	31
5.3	Hướng Phát Triển Tương Lai	32

Chương 1

Giới Thiệu

1.1 Tóm Tắt

Chúng tôi nghiên cứu bài toán *nhận dạng từ khóa ít mẫu tập mở* (Few-Shot Open-Set Keyword Spotting — KWS): một bộ mã hóa embedding duy nhất được huấn luyện một lần trên kho từ vựng lớn, sau đó được triển khai để nhận dạng tập từ khóa tùy chọn của người dùng từ chỉ một số ít mẫu đăng ký, đồng thời từ chối lời nói ngoài từ điển và tiếng im lặng. Chúng tôi xây dựng một pipeline hoàn toàn tái tạo được xoay quanh hai bộ mã hóa nhỏ gọn — mạng tích chập phân tách theo chiều sâu DSCNN-L ($\approx 0,41$ M tham số) và mô hình cạnh chú ý thời gian EdgeSpot-Full $\tau=4$ ($\approx 0,13$ M tham số) — kết hợp với ba bộ trích xuất đặc trưng (MFCC, log-mel và PCEN theo kênh có thể học được) và bốn hàm mục tiêu học độ đo (Triplet, Sub-center ArcFace (SCAF), Generalized End-to-End (GE2E) và Knowledge Distillation cosine (KD) từ mô hình giáo viên Wav2Vec 2.0 đã đóng băng). Toàn bộ hệ thống được huấn luyện trên Multilingual Spoken Words Corpus (MSWC) tiếng Anh và đánh giá chéo kho ngữ liệu trên Google Speech Commands v2 (GSC) theo giao thức EdgeSpot-exact 10 mẫu tập mở với 100 lần chạy ngẫu nhiên. Qua bộ sàng lọc 16 cấu hình chúng tôi chỉ ra rằng: (i) bộ trích xuất PCEN có thể học được là cải tiến đáng tin cậy nhất (lên tới +9,2 điểm độ chính xác tại tỷ lệ chấp nhận sai 1% cho bộ mã hóa cạnh); (ii) hàm mục tiêu GE2E dựa trên centroid vượt trội so với các hàm mục tiêu phân loại trong tổng quát hóa tập mở; (iii) quan trọng nhất, hàm mục tiêu phân loại SCAF sụp đổ khi từ vựng huấn luyện tăng lên 37.387 lớp nếu trọng số loss không được giảm bốn bậc độ lớn. Chúng tôi thêm vào đó đặc trưng hóa việc độ chính xác bão hòa gần hai triệu clip huấn luyện và chứng minh rằng hàm mục tiêu KD cosine đạt độ chính xác ngang GE2E với khoảng một nửa dữ liệu. Cấu hình tốt nhất tổng thể (DSCNN-L + PCEN + GE2E) đạt 86,36% độ chính xác tập mở tại 1% FAR và AUC 95,21 trên GSC test, trong khi mô hình nhỏ gọn nhất (EdgeSpot-Full + PCEN + GE2E) đạt 82,87% với một phần ba số tham số. Chúng tôi công bố mã nguồn đầy đủ, các giao thức huấn luyện/đánh giá và bản demo web chạy offline.

1.2 Bối Cảnh và Động Lực

Nhận dạng từ khóa (Keyword Spotting — KWS) — bài toán phát hiện một tập lệnh thoại nhỏ trong luồng âm thanh liên tục — là công việc luôn bất của hầu hết mọi giao diện thoại hiện đại. Các hệ thống KWS cổ điển được huấn luyện dưới dạng bộ phân loại tập đóng trên một từ điển cố định (ví dụ mười từ lệnh của Google Speech Commands). Thiết kế này có hai hạn chế cấu trúc. Thứ nhất, tập từ khóa bị đóng băng tại thời điểm huấn luyện: hỗ trợ một từ đánh thức hoặc lệnh mới đòi hỏi phải thu thập dữ liệu và huấn luyện lại mô hình. Thứ hai, bộ phân loại softmax về bản chất không phải là tập mở: mọi đầu vào đều bị ép vào một trong các lớp đã biết, nên từ chưa từng gặp và tiếng ồn nền bị phân loại nhầm thành lệnh mà không có cảnh báo, gây ra kích hoạt nhầm. Công trình này hướng đến bài toán ít mẫu tập mở thực tế hơn và khó hơn. Chúng tôi huấn luyện một bộ mã hóa embedding duy nhất trên kho từ vựng rất lớn và đa dạng; khi triển khai, người dùng cuối tự định nghĩa tập từ khóa tùy ý bằng cách cung cấp chỉ vài (k) mẫu đăng ký cho mỗi từ. Mỗi từ khóa được đại diện bởi một *prototype* (trung bình embedding của các mẫu đăng ký); nhận dạng được thực hiện bằng cách khớp prototype gần nhất trong không gian embedding, và một quyết định tập mở tường minh từ chối bất kỳ âm thanh nào quá xa tất cả các prototype. Câu hỏi khoa học trung tâm chúng tôi theo đuổi là điều gì khiến bộ mã hóa như vậy tổng quát hóa được, và đặc biệt là các lựa chọn thiết kế tương tác với quy mô từ vựng huấn luyện như thế nào.

Đóng góp. Các đóng góp chính gồm:

- Một framework KWS ít mẫu tập mở dễ tái tạo, ít phụ thuộc, với hai bộ mã hóa nhỏ gọn, ba bộ trích xuất đặc trưng, bốn hàm mục tiêu độ đo và bốn đầu từ chối tập mở, tất cả chia sẻ giao diện prototype chung (Chapter 3).
- Bộ sàng lọc 16 cấu hình trên MSWC toàn từ vựng, cô lập đóng góp từng trục bằng các delta cặp; PCEN và GE2E nổi lên là hai lợi thế ổn định (Chapter 4).
- Phân tích quy mô cho thấy (a) độ chính xác bão hòa gần ~ 2 M clip huấn luyện và (b) chế độ thất bại của Sub-center ArcFace tại 37k lớp, kèm giải thích theo cơ chế gradient và cách khắc phục thực tế (Chapter 4).
- Nghiên cứu knowledge distillation cho thấy hàm mục tiêu cosine với mô hình giáo viên Wav2Vec 2.0 đóng băng đạt độ chính xác ngang GE2E với khoảng một nửa dữ liệu huấn luyện (Chapter 4).
- Đánh giá chéo kho ngữ liệu hoàn chỉnh theo giao thức EdgeSpot-exact 10 mẫu (100 lần chạy), kèm pipeline phát trực tuyến trên CPU (Silero VAD + máy trạng thái làm mượt) và bản demo web chạy offline (Chapter 3).

1.3 Mục Tiêu Đề Tài

[XEM XÉT — MỤC MỞI DO TRỢ LÝ VIẾT] Mục mới, mô phỏng theo mục “Mục Tiêu Đề Tài” của đề án mẫu.

Mục tiêu chính của đề án là thiết kế, triển khai và đánh giá nghiêm ngặt một hệ thống nhận dạng từ khóa tập mở *không cần huấn luyện lại*, học một embedding có thể chuyển giao duy nhất và hỗ trợ từ điển tùy chọn của người dùng từ một số ít mẫu đăng ký. Cụ thể, chúng tôi hướng đến:

1. xây dựng bộ mã hóa nhỏ gọn, ít phụ thuộc, hoạt động offline trên phần cứng bình thường ($\sim 0,1\text{--}0,4\text{ M}$ tham số);
2. xác định, qua nghiên cứu nhân tố có kiểm soát, bộ trích xuất đặc trưng, cấu trúc bộ mã hóa và hàm mục tiêu độ đo nào tổng quát hóa tốt nhất giữa các kho ngữ liệu;
3. đặc trưng hóa hành vi của các lựa chọn thiết kế khi từ vựng huấn luyện tăng từ vài chục đến vài chục nghìn từ; và
4. cung cấp đánh giá tập mở trung thực (DET/AUC/EER/ACC@FAR) theo giao thức nghiêm ngặt, có thể tái tạo, kèm bản demo phát trực tuyến hoạt động được.

1.4 Kết Quả Kỳ Vọng

[XEM XÉT — MỤC MỞI DO TRỢ LÝ VIẾT] Mục mới, mô phỏng theo mục “Kết Quả Kỳ Vọng” của đề án mẫu.

Hệ thống được kỳ vọng: (i) nhận dạng tập từ khóa do người dùng tự tạo được đăng ký từ ≤ 10 mẫu mỗi từ mà không cần huấn luyện lại; (ii) từ chối lời nói ngoài từ điển và tiếng im lặng với tỷ lệ chấp nhận sai có thể kiểm soát được; (iii) tổng quát hóa qua các điều kiện ghi âm, chứng minh bằng cách huấn luyện trên một kho ngữ liệu (MSWC) và kiểm tra trên một kho ngữ liệu hoàn toàn khác (GSC); và (iv) đủ nhỏ để triển khai offline trên thiết bị đầu cuối. Các sản phẩm đi kèm gồm các bộ mã hóa đã huấn luyện, các script huấn luyện/đánh giá và bản demo web offline có phân tích thời điểm từ khóa trên audio dài.

1.5 Giải Thích Bài Toán Theo Ngôn Ngữ Thông Thường

[XEM XÉT — MỤC MỞI DO TRỢ LÝ VIẾT] Mục mới — giải thích bài toán khoảng 2 trang, không cần kiến thức kỹ thuật, nhằm thuyết phục người đọc về tính hữu ích và thách thức của đề tài.

Hãy tưởng tượng bạn đang nói chuyện với một thiết bị — loa thông minh, tai nghe, xe hơi, máy giặt — và thiết bị đó phản ứng ngay khi bạn nói một lệnh ngắn như “dừng lại”, “tiếp theo”, hoặc một từ đánh thức do bạn tự đặt. Phần mềm luôn lắng nghe liên tục để bắt đúng những từ đó, và chỉ những từ đó thôi, được gọi là hệ thống *nhận dạng từ khóa* (Keyword Spotting — KWS). Nó được cố tình thiết kế nhỏ và luôn chạy, để bộ nhận dạng giọng nói lớn, ngón điện chỉ bật lên *sau khi* nghe thấy từ khóa. KWS vì vậy là cánh cổng của hầu hết mọi giao diện thoại trong cuộc sống hàng ngày.

Tại sao cách tiếp cận thông thường bị hạn chế. Hầu hết hệ thống KWS thương mại được huấn luyện như một bài thi trắc nghiệm: mô hình được cho xem hàng nghìn ví dụ của một danh sách từ *cố định* (ví dụ mười từ *yes, no, up, down, ...*) và học cách chọn đúng một trong số đó cho bất kỳ âm thanh nào. Cách này hoạt động được, nhưng có hai vấn đề thực tế:

1. **Không thể thêm lệnh mới mà không cần sửa máy.** Nếu khách hàng muốn từ đánh thức “Hey Aurora” thay vì “Hey Google”, nhà sản xuất phải thu thập dữ liệu mới và huấn luyện lại mô hình. Từ vựng thực sự được nướng cứng vào mạng nơ-ron.
2. **Nó không thể nói “tôi không biết”.** Một mô hình trắc nghiệm buộc phải chọn một trong các từ đã biết cho *mọi* âm thanh, kể cả tiếng ho, âm nhạc phát từ radio, hay một từ chưa từng nghe. Kết quả là thiết bị bị kích hoạt khi không ai gọi nó — gọi là *kích hoạt nhầm*.

Những gì chúng tôi xây dựng thay thế. Đồ án này xây dựng một hệ thống KWS hoạt động giống người trợ lý hơn nhiều. Thay vì ghi nhớ danh sách từ cố định, hệ thống học một kỹ năng tổng quát: *phân biệt xem hai đoạn âm thanh ngắn có phải cùng một từ hay không*. Kỹ năng này được huấn luyện một lần, trên một bộ sưu tập rất lớn và đa dạng các từ nói. Sau đó, người dùng cuối có thể tự định nghĩa lệnh của mình chỉ bằng cách thu âm vài ví dụ cho mỗi từ — hệ thống không cần huấn luyện lại. Bên trong, mỗi lệnh được tóm tắt thành một điểm trên “bản đồ ngữ nghĩa” (chúng tôi gọi là *embedding*); để nhận dạng, hệ thống đặt âm thanh mới lên bản đồ đó và kiểm tra xem nó gần nhất với lệnh nào. Đặc biệt, nếu âm thanh mới nằm xa *mọi* lệnh, hệ thống được phép trả lời “không phải lệnh nào” — đây là khả năng tập mở cho phép bỏ qua lời nói không liên quan và tiếng ồn.

Tại sao điều này thực sự hữu ích. Lợi ích có ba chiều thực tế. (1) *Cá nhân hóa không cần huấn luyện lại*: một mô hình duy nhất được xuất xưởng hỗ trợ vô số từ điển do người dùng tự chọn — đây chính xác là những gì các trợ lý trên thiết bị bảo vệ quyền riêng tư, công cụ hỗ trợ tiếp cận và điều khiển công nghiệp tùy chỉnh cần. (2) *Bền vững trước điều bất ngờ*: vì hệ thống có thể từ chối, nó tạo ra ít kích hoạt nhầm hơn nhiều trong thực tế. (3) *Dung lượng nhỏ*: các mô hình của chúng tôi đủ nhỏ ($\sim 0,1\text{--}0,4$ triệu tham số) để chạy

trên vi điều khiển hoặc điện thoại mà không cần mạng, bảo vệ quyền riêng tư và hoạt động offline.

Tại sao bài toán này khó. Ba khó khăn khiến đây không chỉ là bài toán đồ chơi. Thứ nhất, *tổng quát hóa*: mô hình phải hoạt động trên các từ — thậm chí trên thiết bị ghi âm và giọng địa phương — mà nó chưa thấy khi huấn luyện, vì vậy chúng tôi cố tình huấn luyện trên một kho ngữ liệu và kiểm tra trên một kho hoàn toàn khác. Thứ hai, *ranh giới tập mở*: dạy mô hình từ chối tự tin không gian vô hạn của “mọi thứ không phải lệnh” khó hơn nhiều so với phân tách một vài từ đã biết, và một hệ thống từ chối quá mạnh sẽ trở nên điếc trong khi hệ thống từ chối quá yếu sẽ gây phiền; chúng tôi phải định lượng đánh đổi này một cách trung thực. Thứ ba và đáng ngạc nhiên nhất, *quy mô*: khi chúng tôi tăng từ vựng huấn luyện từ vài chục từ lên gần bốn mươi nghìn từ, một số kỹ thuật trông xuất sắc ở từ vựng nhỏ lại hoàn toàn thất bại.

Trong các chương tiếp theo, chúng tôi trước tiên xem xét kiến thức nền tảng về cách âm thanh trở thành dữ liệu (Chapter 2); sau đó mô tả chính xác những gì chúng tôi đã xây dựng và đo lường (Chapter 3); trình bày và phân tích kết quả (Chapter 4); và kết thúc với hiện trạng và hướng phát triển tương lai (Chapter 5).

Chương 2

Kiến Thức Nền Tảng và Các Công Trình Liên Quan

[XEM XÉT — MỤC MỞI DO TRỢ LÝ VIẾT] Toàn bộ chương này là mới. Bao gồm kiến thức đại cương: âm thanh được dùng như thế nào, dữ liệu có dạng ra sao, cách chuyển sang mel-spectrum, và các công trình trước mà đề án xây dựng trên đó.

2.1 Từ Âm Thanh Đến Dữ Liệu Số

Âm thanh là sóng áp suất liên tục. Để xử lý trên máy tính, chúng ta *lấy mẫu* sóng với tần số cố định; trong toàn bộ công trình này chúng tôi dùng 16.000 mẫu mỗi giây (16 kHz), là tiêu chuẩn thực tế cho các bài toán giọng nói, nắm bắt mọi tần số liên quan đến từ nói (lên tới 8 kHz theo giới hạn Nyquist). Mỗi clip lệnh thoại được chuẩn hóa thành đúng một giây, tức một vector 16.000 số (*dạng sóng thô*); clip ngắn hơn được đệm bằng số không và clip dài hơn bị cắt bớt. Figure 2.1(a) minh họa dạng sóng đó với từ “yes”. Bản thân dạng sóng là đầu vào kém cho bộ phân loại: nó có số chiều cao, và cùng một từ nói to hơn một chút hoặc lệch về thời gian lại trông rất khác nhau từng mẫu một.

2.2 Biểu Diễn Thời Gian–Tần Số: Mel-Spectrogram

Lời nói dễ mô hình hóa hơn nhiều trong miền *thời gian–tần số*. Chúng tôi trượt một cửa sổ phân tích ngắn (25–40 ms) qua dạng sóng theo các bước nhảy nhỏ (10–20 ms) và, cho mỗi cửa sổ, tính biến đổi Fourier ngắn (STFT) để thu năng lượng tại từng tần số. Hai thực tế tri giác về thính giác người hướng dẫn bước tiếp theo: chúng ta cảm nhận độ cao âm thanh trên thang lôgarít, và nhạy cảm hơn với sự khác biệt ở tần số thấp hơn ở tần số cao. *Thang mel* mã hóa điều đó: nó biến đổi tần số tuyến tính (Hz) thành trục mel tri giác theo công thức

$$m = 2595 \log_{10} \left(1 + \frac{f}{700} \right), \quad (2.1)$$

và một bộ (ở đây 40) bộ lọc tam giác chồng lên nhau cách đều trên trục mel này tổng hợp năng lượng STFT vào 40 *băng mel*. Lấy lôgarít của năng lượng băng (vì độ to cũng được cảm nhận theo lôgarít) cho ra *log-mel spectrogram* ở Figure 2.1(b): một ảnh nhỏ gọn trong đó trục ngang là thời gian, trục dọc là tần số mel, và độ sáng là năng lượng.

MFCC. Một bước cổ điển nữa khử tương quan các băng log-mel bằng biến đổi cosin rời rạc (DCT), tạo ra *Hệ số Cepstral Tần Số Mel* (MFCC). Các hệ số bậc thấp nắm bắt đường bao phổ biến đổi chậm (mang hầu hết thông tin âm vị), vì vậy thông thường — và chúng tôi làm theo — chỉ giữ vài hệ số đầu tiên. Figure 2.1(c) cho thấy bản đồ 10 hệ số MFCC chúng tôi đưa vào bộ mã hóa. Toàn bộ pipeline trích xuất đặc trưng vì vậy là một phép biến đổi cố định, nhỏ, biến một giây âm thanh thành một “ảnh” một kênh có dạng thời-gian×đặc-trưng, mà mạng tích chập có thể xử lý.

PCEN. Lôgarít tĩnh dùng ở trên đơn giản nhưng không thích nghi với điều kiện ghi âm. *Chuẩn hóa Năng Lượng Theo Kênh* (Per-Channel Energy Normalization — PCEN) [10] thay thế bằng kiểm soát khuếch đại tự động theo từng băng *có thể học được* kèm nén mềm; các tham số của nó được học cùng với mạng. PCEN được thiết kế cho phát hiện bền vững từ xa và, như Chapter 4 cho thấy, là cải tiến đáng tin cậy nhất trong nghiên cứu này. Phương trình chính xác được trình bày tại Section 3.3.1.


[XEM XÉT — MỤC MỞI DO TRỢ LÝ VIẾT] Hai hình minh họa dữ liệu mới bên dưới (2.2, 2.3), tạo từ dữ liệu dự án thật, theo phong cách hình ảnh dữ liệu mẫu của đồ án ADAS tham khảo.

Để xây dựng trực giác về những gì mô hình thực sự thấy, Figure 2.2 cho thấy log-mel spectrogram của sáu từ lệnh khác nhau. Mỗi từ có chữ ký thời gian–tần số đặc trưng riêng — đoạn hữu thanh đi lên của “yes”, tiếng bật môi của “stop”, khởi đầu mũi của “no” — và chính cấu trúc này, chứ không phải dạng sóng thô, mà bộ mã hóa học cách so sánh.

Figure 2.3 minh họa cụ thể bộ trích xuất mel: (a) 40 bộ lọc tam giác chồng nhau tổng hợp năng lượng STFT — dày đặc ở tần số thấp và thưa ở tần số cao — và (b) đường cong biến đổi Hz→mel theo Equation (2.1).

2.3 Nhận Dạng Từ Khóa: Tập Đóng vs. Tập Mở

KWS dấu chân nhỏ được phổ biến hóa bởi mạng tích chập phân tách theo chiều sâu (DS-CNN) [1] và sau đó được cải tiến bởi mạng broadcasted residual (BC-ResNet) [2], cả hai đánh đổi độ chính xác lấy số tham số để triển khai trên vi điều khiển. Đây là các bộ phân loại *tập đóng*: chúng đầu ra xác suất trên tập nhãn cố định và vì vậy không thể, theo thiết kế, từ chối đầu vào không biết. Yêu cầu tập mở — chấp nhận từ khóa đã biết trong khi từ chối mọi thứ khác — là điều phân biệt một con số độ chính xác trong phòng thí nghiệm với một động cơ từ đánh thức có thể triển khai thực tế.




Hình 2.1: Từ âm thanh đến đặc trưng, tính từ bản ghi Google Speech Commands thật của từ “yes”. (a) dạng sóng thô 1 s, 16 kHz; (b) log-mel spectrogram 40 băng (ảnh thời gian–tần số tri giác); (c) 10 hệ số MFCC đầu tiên trên $T=47$ khung — tensor thực sự đưa vào bộ mã hóa DSCNN. Tạo từ dữ liệu dự án bằng `make_thesis_figures.py`.

2.4 Học Ít Mẫu và Học Độ Đo

Để hỗ trợ từ điển *tùy ý*, chúng tôi đặt KWS như bài toán học độ đo: mạng học một không gian embedding trong đó các phát âm của cùng một từ gần nhau còn các phát âm của các từ khác nhau ở xa nhau. Mạng prototypical [3] biểu diễn mỗi lớp bằng trung bình (“prototype”) của vài embedding hỗ trợ và phân loại truy vấn bằng prototype gần nhất; triplet embedding [4] tối ưu hóa trực tiếp khoảng cách tương đối. Hàm mất mát Generalized End-to-End (GE2E) [5], ban đầu đề xuất cho xác minh người nói, xây dựng centroid bên trong mỗi batch huấn luyện đúng như triển khai xây dựng prototype, khiến nó phù hợp tự nhiên cho KWS ít mẫu.


Log-mel spectrograms of six Google Speech Commands words



Hình 2.2: Log-mel spectrogram của sáu từ lệnh Google Speech Commands (dữ liệu thật). Các từ khác nhau chiếm các mẫu thời gian–tần số khác nhau rõ ràng — đây là lý do khiến học độ đo trong không gian này hiệu quả.

2.5 Phân Loại Biên Góc và Từ Chối Tập Mở

ArcFace [6] và biến thể sub-center của nó SCAF [7] học embedding phân biệt cao cho nhận dạng khuôn mặt với hàng nghìn danh tính. Một câu hỏi tự nhiên — mà đề án này trả lời phủ định ở quy mô cực lớn — là liệu cơ chế tương tự có chuyển sang hàng chục nghìn lớp từ hay không. OpenMax [8] khớp đuôi Weibull vào các kích hoạt theo từng lớp; điểm năng lượng [9] cung cấp một giải pháp thay thế không cần hiệu chỉnh; chúng tôi điều chỉnh cả hai để hoạt động trên khoảng cách prototype và so sánh với ngưỡng nearest-class-mean đơn giản. Cuối cùng, các mô hình giọng nói tự giám sát như Wav2Vec 2.0 [11] cung cấp các biểu diễn mạnh; chúng tôi dùng Wav2Vec 2.0 đóng băng chỉ như mô hình giáo viên để chưng cất, giữ cho mô hình sinh viên triển khai rất nhỏ.



Hình 2.3: Bộ trích xuất mel. (a) bộ lọc mel tam giác 40 kênh dùng trong công trình này; (b) đường cong biến đổi tri giác Hz→mel. *Tạo từ code trích xuất đặc trưng của dự án.*

Chương 3

Phương Pháp Đề Xuất

[XEM XÉT — MỤC MỚI DO TRỢ LÝ VIẾT] Chương 3 trình bày *những gì đã làm và cách đo lường*, không có kết quả (kết quả ở Chương 4). Các khối từ bản gốc — “Dữ Liệu và Giao Thức”, “Kiến Trúc Hệ Thống” và phần phương pháp “Đánh Giá” — được giữ nguyên; văn bản màu xanh với ký hiệu [+] là phần thêm mới.

Ở mức cao (Figure 3.1) phương pháp có hai giai đoạn chia sẻ một bộ mã hóa đóng băng duy nhất. Trong *giai đoạn huấn luyện*, bộ mã hóa được tối ưu hóa một lần trên MSWC với hàm mục tiêu độ đo. Trong *giai đoạn triển khai*, người dùng đăng ký vài mẫu mỗi từ khóa để tạo prototype, và truy vấn được nhận dạng bằng khoảng cách prototype gần nhất với ngưỡng tập mở tường minh — bộ mã hóa không bao giờ được huấn luyện lại. ^[+]

3.1 Phát Biểu Bài Toán

[XEM XÉT — MỤC MỚI DO TRỢ LÝ VIẾT] Hình thức hóa ngắn gọn để các phương trình được tham chiếu sau có định nghĩa rõ ràng.

Đặt $f_\theta : \mathbb{R}^{T \times F} \rightarrow \mathbb{R}^d$ là bộ mã hóa ánh xạ biểu diễn một giây sang embedding đơn vị chuẩn. Prototype của từ khóa w là trung bình của k embedding hỗ trợ,


$$p_w = \frac{1}{k} \sum_{i=1}^k f_\theta(x_i^{(w)}). \quad (3.1)$$

Truy vấn x được gán cho prototype gần nhất, với điểm tập mở bằng khoảng cách cực tiểu lấy âm,

$$\hat{w}(x) = \arg \min_w d(f_\theta(x), p_w), \quad s(x) = -\min_w d(f_\theta(x), p_w), \quad (3.2)$$

và được chấp nhận là $\hat{w}(x)$ nếu $s(x) \geq \tau$, ngược lại được gán nhãn **không biết**.

[XEM XÉT — MỤC MỚI DO TRỢ LÝ VIẾT] Hình mới (3.2): phép chiếu t-SNE thực của không gian embedding mô hình đã huấn luyện, tạo bằng cách chạy checkpoint local tốt nhất trên GSC. Đây là minh họa trực tiếp nhất về lý do tại sao phương pháp hoạt động.



Hình 3.1: Pipeline KWS ít mẫu tập mở đầu cuối. Bộ mã hóa được huấn luyện một lần; khi triển khai, từ khóa người dùng trở thành prototype và truy vấn được phân loại bằng khoảng cách prototype gần nhất với ngưỡng tập mở.^[+]


Figure 3.2 trực quan hóa không gian học được. Chạy bộ mã hóa đã huấn luyện tốt nhất trên bản ghi GSC thật và chiếu embedding xuống hai chiều, mỗi lệnh đã biết tạo thành một cụm chặt, tách biệt quanh prototype của nó (ngôi sao), trong khi các từ ngoài từ điển (dấu thập xám) nằm ở các khoảng trống giữa các cụm — đúng hình học khiến khớp prototype gần nhất với ngưỡng khoảng cách hiệu quả cho từ chối tập mở.

3.2 Bộ Dữ Liệu và Giao Thức Huấn Luyện

Kho ngữ liệu huấn luyện (MSWC tiếng Anh): Chúng tôi huấn luyện trên phân đoạn tiếng Anh của Multilingual Spoken Words Corpus, sau khi lọc theo số clip tối thiểu chứa 37.387 từ huấn luyện (và 763 từ kiểm định), lấy từ pool metadata ~ 38.150 từ và $\sim 6,6$ M clip. Để nghiên cứu quy mô, chúng tôi tạo các giới hạn $\{20, 50, 220, 620\}$ clip mỗi từ — khoảng $\{0,53; 0,94; 2,05; 2,99\}$ M clip huấn luyện — và hai chế độ thu nhỏ: phân chia Top-500 truyền thống (450 từ train / 50 từ val, đánh giá trên từ xếp hạng 501+ với ≥ 1000 phát âm) và micro-set MLCommons (31 từ khóa) chỉ dùng để xác nhận pipeline và sàng lọc kiến trúc. Ba chế độ từ vựng trải dài hơn ba bậc độ lớn (Figure 3.3); phạm vi này là điều khiến các hiệu ứng quy mô ở Chapter 4 có thể quan sát được.^[+]

Lấy mẫu theo phép học và tăng cường dữ liệu: Mỗi phép học lấy $30 \text{ lớp} \times 20$ phát âm (chỉ các lớp có ≥ 20 clip mới được chọn). Tăng cường trực tuyến kết hợp tiếng ồn nền DEMAND (xác suất 0,5, SNR lấy mẫu trong $[0, 10]$ dB) và áp dụng SpecAugment (một mặt nạ tần số rộng 6, một mặt nạ thời gian rộng 8); nhiễu khuếch đại (± 6 dB) và dịch thời gian (≤ 100 ms) được áp dụng với xác suất 0,5. Figure 3.4 minh họa các tăng cường này trên bản ghi thật: tiếng ồn nền cộng thêm ở 5 dB SNR lấp đầy các vùng yên tĩnh, và các mặt nạ tần số/thời gian của SpecAugment (dải đen) buộc bộ mã hóa không dựa vào bất kỳ băng hay thời điểm nào.^[+]

Kho ngữ liệu đánh giá (GSC v2): Chúng tôi đánh giá chéo kho ngữ liệu trên Google Speech Commands v2. Mẫu đăng ký (hỗ trợ) được lấy từ `validation_list.txt` chính thức; mẫu truy vấn từ `testing_list.txt` (“test”) hoặc các file còn lại (“dev”), tránh rò rỉ dữ liệu. Lớp tổng hợp `_silence_` được tạo từ các đoạn một giây ngẫu nhiên của `_background_noise_`, với các đoạn không chồng lên nhau cho hỗ trợ và truy vấn.



Hình 3.2: Chiều t-SNE embedding từ mô hình DSCNN-L + PCEN + GE2E đã huấn luyện trên audio GSC thật. Điểm màu là sáu lệnh đã biết, ngôi sao là prototype của chúng, dấu thập xám là từ ngoài từ điển. Tạo bằng `make_inference_figures.py` từ checkpoint local.^[+]


Giao thức EdgeSpot-exact: Giao thức chính phân chia 35 từ của GSC thành 11 lớp dương — mười từ lệnh {yes, no, up, down, left, right, on, off, stop, go} cộng `_silence_` — và 25 từ nói âm (không biết). Mỗi lần chạy đăng ký $k=10$ mẫu mỗi từ dương, tính prototype và chấm điểm tối đa 50 mẫu truy vấn mỗi từ (tập con hạt giống cố định). Chúng tôi báo cáo trung bình $\pm$ std qua 100 lần chạy ngẫu nhiên; tính ngẫu nhiên đến từ việc chọn mẫu đăng ký (bản thân từ điển đã biết/không biết cố định qua các lần chạy).

3.3 Kiến Trúc Hệ Thống


3.3.1 Bộ Trích Xuất Đặc Trưng

Tất cả âm thanh là mono, 16 kHz, được cắt/đệm bằng không thành đúng một giây (16.000 mẫu). Chúng tôi hỗ trợ hai tham số hóa phổ, tóm tắt ở Table 3.1.

MFCC (frontend cho DSCNN): Chúng tôi tính 40 hệ số cepstral tần số mel với FFT 1024 điểm, cửa sổ Hann 640 mẫu (40 ms), bước 320 mẫu (20 ms) và `center=False`; bộ lọc mel dùng thang Slaney và chuẩn hóa diện tích Slaney, log được lấy là $10 \log_{10}(\cdot)$



Hình 3.3: Kích thước từ vựng huấn luyện cho ba chế độ (thang lôgarít). Micro-set chỉ dùng để sàng lọc; MSWC tiếng Anh đầy đủ là chế độ chính. ^[+]



Hình 3.4: Tăng cường dữ liệu trong huấn luyện trên từ “yes” (dữ liệu thật): (a) log-mel sạch; (b) cộng tiếng ồn nền thật tại 5 dB SNR; (c) cộng mặt nạ tần số và thời gian SpecAugment. ^[+]

theo sau là DCT-II trực giao. Chỉ giữ 10 hệ số đầu và hoán vị thành tensor $(1, 47, 10) = (\text{kênh}, T_{\text{khung}}, \text{đặc trưng})$, trong đó $T = 47 = \lfloor (16000 - 1024)/320 \rfloor + 1$.

Log-mel (frontend cho EdgeSpot/BC-ResNet): Dùng 40 băng mel với FFT 512 điểm, cửa sổ 400 mẫu (25 ms), bước 160 mẫu (10 ms) và `center=True`, tạo ra $(1, 40, 101)$. Nén lôgarít được ủy quyền cho lớp PCEN.

PCEN có thể học: Chuẩn hóa năng lượng theo kênh [10] áp dụng bộ làm mượt IIR bậc một nhân quả $M_t = (1 - s)M_{t-1} + sE_t$ theo sau là khuếch đại thích nghi và nén dải động,

$$\text{PCEN}(E_t) = \left(\frac{E_t}{(\epsilon + M_t)^\alpha} + \delta \right)^r - \delta^r, \quad (3.3)$$

với các tham số học được α, δ, r, s (khởi tạo 0,96; 2,0; 0,5; 0,04; $\epsilon=10^{-6}$).

Bảng 3.1: Các cấu hình bộ trích xuất đặc trưng.

	MFCC	Log-mel
Tần số mẫu	16 kHz, mono, 1 s	
Kích thước FFT	1024	512
Cửa sổ / bước	40/20 ms	25/10 ms
center	False	True
Băng mel	40	40
Hệ số đầu ra	10 (DCT đầu tiên)	40 (mel)
Hình dạng tensor	(1, 47, 10)	(1, 40, 101)
PCEN có thể học	tùy chọn	tùy chọn

Bảng 3.2: So sánh bộ mã hóa. Chuẩn hóa ℓ_2 áp dụng ngoài bộ mã hóa để các hàm mất mát và bộ phân loại triển khai đều hoạt động trên siêu cầu.


Bộ mã hóa	Frontend	d	Tham số
DSCNN-L	MFCC / mel(+PCEN)	276	0,413 M
EdgeSpot-Full $\tau=4$	mel(+PCEN)	64	0,131 M
EdgeSpot-Lite	mel(+PCEN)	64	< 0,131 M
BC-ResNet-FS $\tau=4$	mel(+PCEN)	64	$\sim 0,1$ M

3.3.2 Bộ Mã Hóa


DSCNN-L: Mạng tích chập phân tách theo chiều sâu xây dựng từ bảng kích thước: một khối tích chập ban đầu Conv(1 $\rightarrow$ 276, 10 $\times$ 4, stride 2 $\times$ 1) với đệm “same” bất đối xứng kiểu TensorFlow, theo sau là năm khối phân tách theo chiều sâu (276 kênh, kernel 3 $\times$ 3; khối đầu strides 2 $\times$ 2). Tất cả khối trừ khối cuối dùng BatchNorm+ReLU; khối cuối dùng LayerNorm (không có affine). Global average pool trực tiếp cho ra embedding nên chiều embedding bằng chiều rộng kênh, $d = 276$. DSCNN-L có $\approx 0,413$ M tham số.

EdgeSpot-Full ($\tau=4$): Bộ mã hóa cạnh thu nhỏ chiều rộng hoạt động trên đầu vào mel/PCEN (1, 40, 101). Một stem 5 $\times$ 5 stride-(2, 1) cấp cho bốn giai đoạn khối fused-temporal và broadcasted-residual “lite” với giãn thời gian tăng dần (1, 2, 4, 8); một khối sụp đổ tần số theo chiều sâu lấy trung bình tần số thành chuỗi (C, T); một tích chập vị trí theo chiều sâu và một khối chú ý thời gian đơn đầu ($d = 64$) mô hình hóa cấu trúc thời gian tầm xa; cuối cùng một đầu thời gian theo chiều sâu và global pooling tạo ra embedding 64 chiều. EdgeSpot-Full $\tau=4$ có $\approx 0,131$ M tham số, nhỏ hơn DSCNN-L $\sim 3,2$ lần.

[XEM XÉT — MỤC MỞI DO TRỢ LÝ VIẾT] Hai sơ đồ khối TikZ mới cho các bộ mã hóa (3.5, 3.6) — tương tự hình kiến trúc của đề án mẫu nhưng vẽ đúng cho mạng tùy chỉnh của đề án này — cùng hình accuracy-vs-kích thước (3.7).



Hình 3.5: Sơ đồ khối DSCNN-L: CNN phân tách theo chiều sâu, $\approx 0,41$ M tham số. Embedding bằng chiều rộng kênh cuối (276); không có phép chiếu tuyến tính. ^[+]



Hình 3.6: Sơ đồ khối EdgeSpot-Full ($\tau=4$): frontend mel/PCEN, các khối fused-temporal và broadcasted-residual với giãn tăng dần, sụp đổ tần số, giai đoạn chú ý thời gian một đầu, $\approx 0,13$ M tham số. ^[+]

3.3.3 Các Hàm Mục Tiêu Học Độ Đo

Tất cả hàm mục tiêu được huấn luyện theo phép học: mỗi phép học lấy mẫu $n_{\text{cls}}=30$ lớp với $n_{\text{spp}}=20$ phát âm mỗi lớp (600 embedding/phép học).

Triplet: Hàm mất mát triplet bán-khó [4] với khoảng cách Euclid, $\mathcal{L} = \frac{1}{N} \sum \max(0, d(a, p) - d(a, n) + m)$, với khai thác positive khó nhất và khai thác negative bán-khó kiểu FaceNet.

Sub-center ArcFace (SCAF): Softmax biên góc cộng với $K=3$ sub-center mỗi lớp. Logit mỗi lớp là max cosine qua các sub-center, $\cos \theta_c = \max_{j \leq K} w_{c,j}^\top z$; biên cộng $m=0,5$ áp dụng cho lớp đích và logit được nhân $s=30$ trước cross-entropy.


GE2E (centroid): Hàm mất mát generalized end-to-end [5] phản ánh triển khai: trong mỗi phép học mỗi lớp được chia thành hỗ trợ/truy vấn; centroid là trung bình hỗ trợ chuẩn hóa ℓ_2 và truy vấn được phân loại bằng cosine similarity có thang và bias học được, tối ưu hóa bằng cross-entropy. GE2E trực tiếp tối ưu hóa mục tiêu đăng ký-rời-khốp của Equations (3.1) and (3.2).

Chưng cất cosine (KD): Chúng tôi thêm chưng cất từ mô hình giáo viên Wav2Vec 2.0-base đóng băng (lớp ẩn 16, mean-pooled, chiếu sang $d=64$ bởi đầu sub-center-ArcFace đã huấn luyện). Hàm mất mát chưng cất là thuần cosine embedding,

$$\mathcal{L}_{\text{KD}} = 1 - \frac{1}{N} \sum_i \cos(f_\theta(x_i), g_{\text{giáo viên}}(x_i)), \quad (3.4)$$

không có nhiệt độ/nhân mềm. Embedding giáo viên được tính trước offline và tra cứu theo đường dẫn file khi huấn luyện.

Kết hợp lại: Chúng tôi tạo tổng có trọng số, ví dụ `scaf_ge2e`, `kd_ge2e`, `kd_scaf`, `kd_scaf_ge2e`. Một chi tiết triển khai quan trọng (và là phát hiện thực nghiệm chính, Chapter 4) là trọng số SCAF: trong KD được đặt là 5×10^{-5} trong khi trọng số GE2E/KD là 1,0.



Hình 3.7: Đánh đổi độ chính xác vs. kích thước mô hình. DSCNN-L dẫn đầu về độ chính xác; EdgeSpot-Full đạt điểm cạnh tranh với một phần ba tham số; KD nâng mô hình nhỏ gọn ở dữ liệu ít. (Số liệu chi tiết ở Chapter 4.)^[+]

Tối ưu hóa. Trừ khi ghi chú, huấn luyện dùng Adam (learning rate 10^{-3} , weight decay 10^{-4}), gradient clipping tại 5,0, lịch cosine annealing với warm restarts ($T_0=10$, $T_{\text{mult}}=2$, $\eta_{\text{min}}=10^{-5}$) và hạt ngẫu nhiên cố định (42) với cuDNN determinism.^[+]

3.4 Các Đầu Từ Chối Tập Mở

[XEM XÉT — MỤC MỚI DO TRỢ LÝ VIẾT] Mục mới mô tả bốn đầu từ chối đã triển khai.

Tất cả các đầu chia sẻ giao diện prototype và chỉ khác nhau ở điểm từ chối; từ khóa dự đoán luôn là lớp argmin khoảng cách (Equation (3.2)). (i) **Nearest-class-mean (NCM, “L2 trực tiếp”)** — mặc định của chúng tôi — từ chối khi khoảng cách prototype tối thiểu vượt ngưỡng, dùng khoảng cách thô không chuẩn hóa xác suất. (ii) **OpenMax** [8] khớp đuôi Weibull với khoảng cách hỗ trợ-tới-prototype và dùng $1 - \text{CDF}$ làm điểm thành viên. (iii) **Energy** [9] xem $-d_i$ như logit và dùng năng lượng tự do $E(x) = T \log \sum_i \exp(-d_i/T)$ làm điểm chấp nhận. (iv) **Ngưỡng hiệu chỉnh** ($\mu + 2\sigma$ của khoảng cách hỗ trợ) điều khiển bảng phân tích nhằm lẫn theo từng từ.

3.5 Phương Pháp Đánh Giá

Chúng tôi xem bài toán tập mở là phát hiện nhị phân từ khóa vs. không phải từ khóa kết hợp theo dõi danh tính đa lớp, và xây dựng tất cả chỉ số trên ROC.

- **AUC:** diện tích dưới ROC của điểm tập mở (Equation (3.2)); không phụ thuộc ngưỡng.
- **EER:** tỷ lệ lỗi bằng nhau, điểm hoạt động tối thiểu hóa $|FAR - FRR|$, báo cáo là $(FAR + FRR)/2$.
- **FRR@FAR:** tỷ lệ từ chối sai tại ngưỡng lớn nhất có tỷ lệ chấp nhận sai không vượt mục tiêu (1% hoặc 5%).
- **Open-set ACC@FAR:** độ chính xác chính. Truy vấn đã biết đúng khi được chấp nhận ($s \geq \tau_{FAR}$) và nhận argmin đúng; truy vấn không biết đúng khi bị từ chối. Báo cáo tại $FAR \in \{1\%, 5\%\}$.
- **Keyword ACC:** độ chính xác prototype gần nhất tập đóng chỉ trên truy vấn đã biết (bỏ qua từ chối).
- **F1:** F1 nhị phân từ khóa vs. không biết tại ngưỡng EER.

3.6 Thiết Kế Thực Nghiệm: Những Gì Chúng Tôi Đo

[XEM XÉT — MỤC MỞI DO TRỢ LÝ VIẾT] Mục mới. Phát biểu bốn câu hỏi thực nghiệm sẽ trả lời (không có kết quả — kết quả ở Chương 4).

Các thực nghiệm được tổ chức quanh bốn câu hỏi:

- Q1 — Thiết kế nào quan trọng?** Chúng tôi huấn luyện tất cả $2 \times 2 \times 4 = 16$ tổ hợp $\{\text{DSCNN-L, EdgeSpot-Full}\} \times \{\text{MFCC, PCEN}\} \times \{\text{Triplet, SCAF, GE2E, SCAF+GE2E}\}$ và cô lập từng trục.
- Q2 — Hiệu suất quy mô như thế nào?** Cố định frontend/loss tốt nhất, chúng tôi quét giới hạn $\{20, 50, 220, 620\}$ và tăng từ vệt từ 31 đến 37.387 từ.
- Q3 — Chứng cất có thể thay thế dữ liệu không?** Chúng tôi so sánh GE2E với hàm mục tiêu cosine-KD ở các giới hạn dữ liệu tương đương.
- Q4 — Hệ thống triển khai tốt nhất là gì?** Chúng tôi tổng hợp các cấu hình mạnh nhất theo từng chế độ dữ liệu.

3.7 Triển Khai: Phát Trực Tuyến và Bản Demo

[XEM XÉT — MỤC MỞI DO TRỢ LÝ VIẾT] Mục mới mô tả pipeline trên thiết bị/phát trực tuyến và web demo.

Ngoài bộ mã hóa lỗi, hệ thống bao gồm pipeline phát trực tuyến trên CPU và bản demo web offline. Phát trực tuyến thực hiện phát hiện cửa sổ trượt (cửa sổ 1 s, bước 0,5 s) được kiểm soát bởi Silero VAD: chỉ các cửa sổ VAD đánh dấu là lời nói mới được nhúng và khớp. Một *máy trạng thái* quyết định không phụ thuộc backend (Algorithm 1) ổn định

Algorithm 1 Máy trạng thái quyết định phát trực tuyến (làm mượt + hồi phục).

Require: cửa sổ W , phiếu V , biên $m_{\min}$, hồi phục C

- 1: bộ đệm $\leftarrow \text{deque}(\text{maxlen} = W)$; $t_{\text{cuối}} \leftarrow -\infty$
- 2: **for** mỗi ứng viên c với khoảng $[t_s, t_e]$ **do**
- 3: **if** $t_s - t_{\text{cuối}} < C$ **then**
- 4: phát HỒI_PHỤC; **tiếp tục**
- 5: **end if**
- 6: **if** $\neg c.\text{phát hiện}$ **hoặc** $c.\text{kw} = \text{không biết}$ **hoặc** $c.\text{biên} < m_{\min}$ **then**
- 7: xóa bộ đệm; phát TỪ_CHỐI; **tiếp tục**
- 8: **end if**
- 9: đẩy c ; $k^* \leftarrow$ từ khóa đa số trong bộ đệm
- 10: **if** $\text{phiếu}(k^*) \geq V$ **then**
- 11: $a \leftarrow \arg \max_{\text{độ tin}} \{c \in \text{bộ đệm} : c.\text{kw} = k^*\}$
- 12: $t_{\text{cuối}} \leftarrow a.t_e$; xóa bộ đệm; phát PHÁT_HIỆN(k^*)
- 13: **else**
- 14: phát ĐANG_CHẤM_ĐIỂM
- 15: **end if**
- 16: **end for**

các ứng viên thô thành sự kiện sạch bằng bầu chọn đa số ngắn, kiểm tra biên top-2 và thời gian hồi phục để ngăn kích hoạt trùng lặp. Các module tùy chọn — bộ giảm nhiễu spectral-gating/SpeechBrain và cổng xác minh người nói ECAPA-TDNN — tuân theo cùng mô hình fail-open, bật/tắt runtime.

[HÌNH CẦN XUẤT TỪ COLAB]

Ảnh chụp màn hình bản demo web offline (bộ chuyển đổi mô hình + xem thời điểm audio dài). Xuất từ demo local tại 1280×720 và lưu thành `assets/demo_ui.png`; sau đó thay hộp này bằng `\includegraphics`.

Chương 4

Kết Quả và Phân Tích

[XEM XÉT — MỤC MỚI DO TRỢ LÝ VIẾT] Toàn bộ chương này là mới. Báo cáo và phân tích các số đo, tham chiếu đến hình kết quả trong `assets/`.

Tất cả số liệu là trung bình $\pm$ std qua giao thức EdgeSpot-exact 10 mẫu (100 lần chạy trên GSC test, ký hiệu test100). Cao hơn tốt hơn cho ACC/AUC/F1/Keyword-ACC; thấp hơn tốt hơn cho EER/FRR.

4.1 Diễn Biến Huấn Luyện

[XEM XÉT — MỤC MỚI DO TRỢ LÝ VIẾT] Mục mới. Figure 4.1 được vẽ từ *log TensorBoard local* thật (không cần huấn luyện lại), tương tự hình “Loss Huấn Luyện và Kiểm Định” của đồ án mẫu.


Figure 4.1 cho thấy quỹ đạo huấn luyện thực sự của mô hình neo Microset (EdgeSpot-Full + SCAF+GE2E), đọc trực tiếp từ log TensorBoard đã lưu. Hàm mất mát SCAF+GE2E giảm mượt từ $\sim 15,5$ xuống $\sim 1,3$, AUC kiểm định tăng lên và ổn định gần 98%, độ chính xác tập mở GSC-dev đạt ngưỡng $\sim 85\%$ — một quỹ đạo lành mạnh, không bị overfit.

4.2 Q1: Trục Thiết Kế Nào Quan Trọng

Table 4.1 báo cáo bộ sàng lọc 16 cấu hình đầy đủ trên MSWC toàn từ vựng (cap-620), và Figure 4.2 xếp hạng các cấu hình trực quan. Hai phát hiện ngay lập tức: các pipeline dùng PCEN chiếm đỉnh xếp hạng, và hàm mất mát centroid GE2E là tốt nhất cho mọi backbone. Hàm mục tiêu phân loại SCAF (và kết hợp SCAF+GE2E ở trọng số đầy đủ) *sup đố* ở quy mô này — hiện tượng được phân tích ở Section 4.3.

Delta hiệu ứng cặp. Cô lập từng trục (Table 4.2, Figure 4.3) cho thấy hai lợi thế ổn định. PCEN cải thiện mọi backbone — ấn tượng nhất là bộ mã hóa cạnh (+9,22 ACC,

Training dynamics of the Microset anchor (EdgeSpot-Full + SCAF+GE2E)



Hình 4.1: Diễn biến huấn luyện thực sự của mô hình neo Microset (EdgeSpot-Full + SCAF+GE2E), từ log TensorBoard local: (a) hàm mất mát huấn luyện; (b) AUC kiểm định và GSC-dev ACC@1%FAR theo epoch. Tạo bằng `make_training_curves.py`.^[+]

+21,86 F1) — và GE2E nhất quán vượt triplet. Bộ trích xuất đặc trưng vì vậy mang gánh nặng biểu diễn nhiều hơn theo tỷ lệ khi backbone nhỏ.

4.3 Q2: Quy Mô — Bảo Hòa và Sụp Đổ SCAF

Độ chính xác bảo hòa gần 2 M clip. Figure 4.4 và Table 4.3 quét giới hạn mỗi từ cho frontend/loss tốt nhất (PCEN+GE2E). Có bước nhảy lớn giữa cap-50 và cap-220 (+3,55 ACC cho DSCNN, +3,79 cho EdgeSpot tại 5% FAR) và vùng phẳng từ cap-220 đến cap-620 (+0,33/−0,02). Độ chính xác thực sự bảo hòa dữ liệu tại ~2 M clip huấn luyện.

Sụp đổ SCAF tại 37k lớp. Kết quả ấn tượng nhất của nghiên cứu quy mô là thất bại định tính. Trên micro-set 31 lớp và phân chia Top-500 ~500 lớp, SCAF và SCAF+GE2E rất xuất sắc (AUC ≈ 95). Tuy nhiên, trên từ vựng đầy đủ 37.387 lớp với trọng số SCAF mặc định 1,0, huấn luyện sụp đổ từ epoch 2: AUC kiểm định ghim tại 0,5000, độ chính xác GE2E trong phép học giảm xuống $\approx 0,033$ (ngẫu nhiên), và các chỉ số GSC trở nên suy biến (AUC 50, F1 0, FRR=100%, keyword ACC 9,09%). Cơ chế là mất cân bằng gradient: thang logit ArcFace ($s=30$) nhân qua $\sim 3,7 \times 10^4$ lớp tạo ra gradient phân loại áp đảo các số hạng centroid/cosine. Các biện pháp khắc phục thực tế: (i) giảm trọng số SCAF xuống $\sim 5 \times 10^{-5}$, (ii) làm ấm biên/thang, hoặc (iii) bỏ số hạng phân loại và dùng GE2E hoặc KD.

Bảng 4.1: Bộ sàng lọc 16 cấu hình đầy đủ trên MSWC toàn từ vựng (cap-620), GSC test100 @ 1% FAR. “súp.” đánh dấu súp đổ suy biến (AUC=50, F1=0, FRR=100%). Tốt nhất in đậm.

Bộ mã hóa	Đặc trưng	Loss	ACC _{1%}	AUC	EER	F1
DSCNN	MFCC	Triplet	71,52	75,55	31,41	57,17
DSCNN	MFCC	SCAF	70,08	55,04	46,41	41,38
DSCNN	MFCC	GE2E	77,08	86,46	21,95	68,50
DSCNN	MFCC	SCAF+GE2E	69,04	47,78	52,15	35,93
DSCNN	PCEN	Triplet	79,98	90,65	17,57	74,14
DSCNN	PCEN	SCAF	69,44	50,00	50,00	súp.
DSCNN	PCEN	GE2E	82,34	92,42	14,89	77,75
DSCNN	PCEN	SCAF+GE2E	69,44	50,00	50,00	súp.
Edge	MFCC	Triplet	69,63	52,84	48,05	39,79
Edge	MFCC	SCAF	69,44	50,00	50,00	súp.
Edge	MFCC	GE2E	70,76	65,30	39,05	48,82
Edge	MFCC	SCAF+GE2E	69,67	50,88	50,39	37,57
Edge	PCEN	Triplet	79,58	89,85	18,22	73,29
Edge	PCEN	SCAF	69,44	50,00	50,00	súp.
Edge	PCEN	GE2E	79,98	87,23	20,23	70,68
Edge	PCEN	SCAF+GE2E	69,44	50,00	50,00	súp.

Bảng 4.2: Delta hiệu ứng cặp (điểm phần trăm), MSWC toàn từ vựng, GSC test100 @ 1% FAR. Dương nghĩa là tùy chọn đầu tiên tốt hơn.


So sánh (các trục khác cố định)	$\Delta\text{ACC}_{1\%}$	ΔAUC	ΔF1
PCEN – MFCC (DSCNN, GE2E)	+5,26	+5,96	+9,25
PCEN – MFCC (Edge, GE2E)	+9,22	+21,93	+21,86
GE2E – Triplet (DSCNN, PCEN)	+2,36	+1,77	+3,61
DSCNN – Edge (PCEN, GE2E)	+2,36	+5,19	+7,07

[HÌNH CẦN XUẤT TỪ COLAB]

Đường súp đổ cho run SCAF+GE2E *toàn từ vựng* (AUC kiểm định ghim 0,50 từ epoch 2). Log của run cụ thể này *không có* trong repo local (chỉ có log Microset/Top500), nên phải chạy lại trên Colab. Khi có thư mục runs/ TensorBoard, vẽ bằng make_training_curves.py và lưu thành assets/scaf_collapse.png. **Lưu ý:** đường huấn luyện lành mạnh Microset đã có tại Figure 4.1; hộp đổ này chỉ dành cho run súp đổ đối chiếu.

4.4 Q3: Chứng Cắt Đối Kiến Thức Giáo Viên Lấy Dữ Liệu

Table 4.4 chứng cắt mô hình giáo viên Wav2Vec 2.0 đóng băng vào sinh viên EdgeSpot nhỏ gọn. Ở cap-50, KD cải thiện mọi chỉ số so với GE2E (+3,60 ACC@1%FAR, −4,78 EER, +6,31 F1) và, đáng chú ý, KD ở cap-50 khớp GE2E ở cap-220 — cùng độ chính xác




Hình 4.2: Các cấu hình xếp hạng theo GSC ACC@1%FAR (sàng lọc giai đoạn 1 trên MSWC đầy đủ). Pipeline PCEN+GE2E dẫn đầu; màu sắc mã hóa backbone× đặc trưng. *Hình kết quả từ dự án.*

với khoảng một nửa clip huấn luyện. KD cũng bão hòa sớm (cap-50→cap-220 gần như phẳng), cho thấy mô hình giáo viên tiếm hầu hết thiên kiến quy nạp hữu ích từ dữ liệu hạn chế.

4.5 Q4: Các Hệ Thống Triển Khai Tốt Nhất

Table 4.5 tổng hợp các cấu hình mạnh nhất theo từng chế độ dữ liệu. Ba điểm nổi bật:

- **Tốt nhất tổng thể:** DSCNN-L+PCEN+GE2E (cap-620) đạt $86,36 \pm 1,29$ ACC@1%FAR và $89,93 \pm 0,65$ tại 5% FAR, với AUC 95,21, EER 11,32, F1 82,73, keyword ACC 92,92%.
- **Tốt nhất nhỏ gọn:** EdgeSpot-Full+PCEN+GE2E (cap-620) đạt $82,87 \pm 1,22$ ACC@1%FAR với 0,131 M tham số — cách hệ thống tốt nhất $\sim 3,5$ điểm nhưng nhỏ hơn ba lần.
- **Tốt nhất từ vựng nhỏ:** trên phân chia Top-500, kết hợp EdgeSpot+PCEN+SCAF+GE2E là mô hình nhỏ gọn mạnh nhất ($85,62 \pm 1,04$ ACC@1%FAR, AUC 95,34), xác nhận rằng kết hợp lai xuất sắc *khi số lớp đủ nhỏ để không kích hoạt sụp đổ*.



Hình 4.3: Các delta hiệu ứng cập chính. PCEN và GE2E là hai cải tiến nhất quán qua các backbone. *Hình kết quả từ dự án.*


Bảng 4.3: Quét quy mô dữ liệu (PCEN+GE2E), GSC test100. ACC tại 5% FAR.

Bộ mã hóa	Giới hạn	ACC _{5%}	AUC	EER	F1
DSCNN-L	20	86,05	91,57	16,25	75,90
	50	84,68	90,45	17,42	74,34
	220	88,23	93,87	12,78	80,67
	620	88,56	94,04	12,53	81,02
EdgeSpot	20	83,06	87,22	20,40	70,46
	50	82,24	87,74	20,19	70,73
	220	86,03	91,31	16,47	75,61
	620	86,01	91,34	16,64	75,38

4.6 Suy Luận Trên Audio Dài

[XEM XÉT — MỤC MỚI DO TRỢ LÝ VIẾT] Mục mới, tương tự mục “Kết Quả Suy Luận” của đề án mẫu. Figure 4.6 được tạo bằng cách thực sự chạy mô hình đã huấn luyện trên bản ghi đa từ thật.

Để xác minh hệ thống hoạt động đầu cuối — không chỉ trên clip kiểm tra riêng lẻ — chúng tôi đăng ký prototype cho 17 từ khóa (10 mẫu mỗi từ từ GSC) và chạy suy luận prototype gần nhất trên bản ghi liên tục đa từ thật. Figure 4.6 chồng lên dạng sóng từ khóa dự đoán và khoảng cách prototype của nó cho 16 đoạn nói đầu tiên. Mô hình nhận dạng đúng 15/16 đoạn ($\approx 94\%$); lỗi duy nhất (“sheila”, tên dài, hiếm) cũng có khoảng cách prototype lớn nhất — đúng là tín hiệu mà ngưỡng tập mở dùng để đánh dấu phát



Hình 4.4: Độ chính xác chéo kho ngữ liệu vs. khối lượng dữ liệu huấn luyện (giới hạn mỗi từ). Hiệu suất bão hòa gần ~2M clip (vùng tô màu). *Tạo từ kết quả dự án.*


Bảng 4.4: Chứng cất kiến thức vs. GE2E (sinh viên EdgeSpot), GSC test100.

Giới hạn	Loss	ACC _{1%}	ACC _{5%}	EER	F1
50	GE2E	77,14	82,24	20,19	70,73
50	KD	80,74	85,82	15,41	77,04
220	GE2E	—	86,03	16,47	75,61
220	KD	80,82	85,90	15,36	77,10


hiện độ tin thấp.

Bảng 4.5: Tổng hợp hệ thống tốt nhất theo chế độ dữ liệu (GSC test100, EdgeSpot-exact 10 mẫu, 100 lần chạy). “sựp.” = sựp đổ suy biến.

Chế độ	Bộ mã hóa	Loss	Tham số	ACC _{1%}	ACC _{5%}	AUC	EER	F1	KW
Micro (31)	EdgeSpot	SCAF+GE2E	0,131M	84,61	86,12	95,61	11,54	82,41	77,66
Top-500	EdgeSpot	SCAF+GE2E ep13	0,131M	85,62	88,79	95,34	11,51	82,45	90,44
Top-500	DSCNN-L	GE2E	0,413M	81,55	86,56	93,17	14,00	78,97	88,62
Full cap20	DSCNN-L	GE2E	0,413M	82,10	86,05	91,57	16,25	75,90	88,90
Full cap220	DSCNN-L	GE2E	0,413M	—	88,23	93,87	12,78	80,67	89,82
Full cap620	DSCNN-L	GE2E ep300	0,413M	86,36	89,93	95,21	11,32	82,73	92,92
Full cap620	EdgeSpot	GE2E ep300	0,131M	82,87	86,76	92,41	14,82	77,85	87,29
Full cap50	EdgeSpot	KD	0,131M	80,74	85,82	91,19	15,41	77,04	87,95
Full cap220	EdgeSpot	SCAF+GE2E	0,131M	sựp.	sựp.	50,00	50,00	sựp.	9,09




(a) Đường cong DET (DSCNN-L+PCEN+GE2E).




(b) Bản đồ nhiệt ACC@1%FAR (cap-620).

Hình 4.5: Các góc nhìn về điểm hoạt động. (a) Đường cong đánh đổi lỗi phát hiện của hệ thống tổng thể tốt nhất; (b) bản đồ nhiệt độ chính xác qua các cấu hình cap-620. Hình kết quả từ dự án.



Hình 4.6: Suy luận prototype gần nhất trên bản ghi dài thật. Trên: dạng sóng với tô màu đúng (xanh)/sai (đỏ) mỗi đoạn. Dưới: khoảng cách prototype tối thiểu và từ khóa dự đoán mỗi đoạn. Tạo từ checkpoint local bằng `make_inference_figures.py`.^[+]



Hình 4.7: Tương tác frontend $\times$ loss (ACC@1%FAR). Ô PCEN+GE2E chi phối; các ô chỉ phân loại suy giảm ở quy mô từ vựng đầy đủ.^[+]

Chương 5

Kết Luận

[XEM XÉT — MỤC MỞI DO TRỢ LÝ VIẾT] Chương mới (~2 trang): hiện trạng, điểm mạnh, điểm yếu, hướng phát triển tương lai.

5.1 Hiện Trạng

Đồ án này nhằm xây dựng hệ thống nhận dạng từ khóa thoát khỏi hai giới hạn cấu trúc của các engine từ đánh thức cổ điển — từ vựng đóng băng và không thể từ chối — đồng thời hiệu được, chứ không chỉ đơn thuần báo cáo, điều gì khiến hệ thống như vậy hoạt động khi từ vựng huấn luyện tăng. Chúng tôi đã cung cấp một pipeline hoàn chỉnh, có thể tái tạo, ít phụ thuộc: hai bộ mã hóa nhỏ gọn (DSCNN-L $\approx 0,41$ M và EdgeSpot-Full $\approx 0,13$ M tham số), ba bộ trích xuất đặc trưng, bốn hàm mục tiêu học độ đo, bốn đầu từ chối tập mở, engine phát trực tuyến CPU và bản demo web offline. Mọi hệ thống được huấn luyện trên MSWC tiếng Anh và đánh giá chéo kho ngữ liệu trên GSC v2 theo một giao thức EdgeSpot-exact 10 mẫu nghiêm ngặt với 100 lần chạy ngẫu nhiên.

Kết quả chính là nhận dạng từ khóa ít mẫu tập mở khả thi và thậm chí mạnh ở quy mô từ vựng thật: huấn luyện một lần trên 37.387 từ, cấu hình tốt nhất (DSCNN-L + PCEN + GE2E) đạt 86,36% độ chính xác tập mở tại 1% FAR và AUC 95,21 trên kho ngữ liệu chưa từng được huấn luyện, trong khi mô hình nhỏ hơn ba lần vẫn cách vài điểm. Người dùng có thể tự định nghĩa tập từ khóa tùy ý từ mười ví dụ mỗi từ, không cần huấn luyện lại, và hệ thống có thể từ chối lời nói không biết và tiếng im lặng.

5.2 Điểm Mạnh và Điểm Yếu

Điều hoạt động tốt. Ba phát hiện bền vững và có thể chuyển giao. (1) Bộ trích xuất PCEN có thể học được là cải tiến đơn lẻ đáng tin cậy nhất, và nó giúp bộ mã hóa nhỏ hơn nhiều nhất — một đòn bẩy hữu ích chính xác khi ngân sách tham số hạn chế nhất. (2) Hàm mục tiêu centroid GE2E, tối ưu hóa cùng tính toán đăng ký-rời-khớp dùng khi

triển khai, nhất quán vượt cả triplet lẫn phân loại cho tổng quát hóa tập mở. (3) Mô hình giáo viên Wav2Vec 2.0 đóng bằng chũm cất với hàm mất mát cosine đơn giản cho phép mô hình nhỏ gọn đạt độ chính xác ngang GE2E với khoảng một nửa dữ liệu.

Điểm yếu / những gì chúng tôi học được theo cách khó. Kết quả phủ định rõ ràng nhất là sụp đổ của hàm mục tiêu phân loại Sub-center ArcFace (SCAF) ở quy mô 10^4 lớp: một hàm mất mát xuất sắc ở hàng chục đến hàng trăm lớp embedding đến nghiệm tầm thường ở hàng chục nghìn lớp trừ khi trọng số của nó bị cắt bốn bậc độ lớn. Đây là bài học cảnh báo quan trọng cho bất kỳ ai mở rộng hàm mất mát biên góc sang không gian nhãn lớn. Hai hạn chế nữa ràng buộc các yêu cầu hiện tại. Thứ nhất, các điểm hoạt động ACC@FAR/FRR@FAR được đọc từ ROC đánh giá (ngưỡng oracle) chứ không được chuyển từ tập hiệu chỉnh độc lập. Thứ hai, đăng ký cố định ở $k=10$ mẫu và các con số độ trễ phát trực tuyến là ngân sách thiết kế, không phải điểm chuẩn thực địa đo được.

5.3 Hướng Phát Triển Tương Lai

Bốn hướng xuất phát trực tiếp từ các hạn chế trên. (1) *Nhạy cảm k -mẫu*: quét $k \in \{1, 3, 5, 10\}$ để lập biểu đồ đường cong độ chính xác vs. nỗ lực đăng ký, là chỉ số người dùng cuối thực sự cảm nhận được. (2) *Ngưỡng hiệu chỉnh*: học hoặc chuyển ngưỡng tập mở từ tập phân chia độc lập và báo cáo ACC@FAR thực tế triển khai. (3) *Điểm chuẩn trên thiết bị*: đo độ trễ đầu cuối, tỷ lệ kích hoạt nhằm mỗi giờ và tỷ lệ bỏ sót trên phần cứng mục tiêu. (4) *Ổn định phân loại ở quy mô lớn*: làm âm biên/thang, chương trình giảng dạy hoặc cắt tỉa sub-center để khôi phục sức mạnh phân biệt của hàm mất mát biên góc mà không sụp đổ — có khả năng kết hợp các cụm chặt của SCAF với hàm mục tiêu khớp-triển khai của GE2E ở toàn bộ từ vựng.

Tóm lại, đề án trình bày một bộ nhận dạng từ khóa tập mở, không cần huấn luyện lại, có thể triển khai được và, quan trọng không kém, một bản đồ thực nghiệm rõ ràng về lựa chọn thiết kế nào giúp ích, ở đâu chúng bảo hòa và ở đâu chúng thất bại khi bài toán mở rộng quy mô.

Tài liệu tham khảo

- [1] Y. Zhang, N. Suda, L. Lai, và V. Chandra, “Hello edge: Keyword spotting on microcontrollers,” *arXiv:1711.07128*, 2017.
- [2] B. Kim, S. Chang, J. Lee, và D. Sung, “Broadcasted residual learning for efficient keyword spotting,” *Interspeech*, 2021.
- [3] J. Snell, K. Swersky, và R. Zemel, “Prototypical networks for few-shot learning,” *NeurIPS*, 2017.
- [4] F. Schroff, D. Kalenichenko, và J. Philbin, “FaceNet: A unified embedding for face recognition and clustering,” *CVPR*, 2015.
- [5] L. Wan, Q. Wang, A. Papir, và I. L. Moreno, “Generalized end-to-end loss for speaker verification,” *ICASSP*, 2018.
- [6] J. Deng, J. Guo, N. Xue, và S. Zafeiriou, “ArcFace: Additive angular margin loss for deep face recognition,” *CVPR*, 2019.
- [7] J. Deng, J. Guo, T. Liu, M. Gong, và S. Zafeiriou, “Sub-center ArcFace: Boosting face recognition by large-scale noisy web faces,” *ECCV*, 2020.
- [8] A. Bendale và T. E. Boult, “Towards open set deep networks,” *CVPR*, 2016.
- [9] W. Liu, X. Wang, J. Owens, và Y. Li, “Energy-based out-of-distribution detection,” *NeurIPS*, 2020.
- [10] Y. Wang, P. Getreuer, T. Hughes, R. F. Lyon, và R. A. Saurous, “Trainable frontend for robust and far-field keyword spotting,” *ICASSP*, 2017.
- [11] A. Baevski, H. Zhou, A. Mohamed, và M. Auli, “wav2vec 2.0: A framework for self-supervised learning of speech representations,” *NeurIPS*, 2020.
- [12] M. Mazumder và cộng sự, “Multilingual Spoken Words Corpus,” *NeurIPS Datasets and Benchmarks*, 2021.
- [13] P. Warden, “Speech Commands: A dataset for limited-vocabulary speech recognition,” *arXiv:1804.03209*, 2018.